

Trabalho 1 – Construção de Corpora, Classificação e Similaridade de Texto

Objetivos:

- Coletar, refinar, anotar datasets textuais.
- Tarefas de classificação e similaridade textual, usando:
 - Bag-of-word + TFIDF
 - Word Embeddings

1. (3,0) Construção do corpus de questões:

- A partir de site de concursos como: <https://www.pciconcursos.com.br/provas/ti/>, colete questões de prova para formar o dataset. Seu dataset deve:
- a. Escolher questões de computação em ao menos 3 subáreas. Coletar ao menos 500 questões de cada subárea.
 - b. As questões devem, preferencialmente, serem de concursos que ocorreram nos últimos 6 anos.
 - c. Converter as questões de pdf para txt.
 - d. Filtrar e pré-processar os textos (eliminar questões com problemas de conversão)
 - e. Organizar por ano, por questão (separar enunciado das respostas) e por subárea.
 - f. incluir o gabarito da questão
 - g. gerar estatísticas do corpus
 - h. exportar os dados finais para o formato json (estrutura a definir)
 - i. construir dataset card como documentação

2. (2,0) Construção do corpus de similaridade de palavras:

- a. Processe o dataset do item 1:
 - i. tokenize, lematize e remova stopwords
 - ii. encontre as 200 mais representativas
 - iii. combine-as aleatoriamente duas a duas até formar 100 pares
- b. Crie uma escala likert de similaridade
- c. Anote manualmente os pares de acordo com essa escala (mínimo 2 alunos)
- d. Avaliar a concordância entre os alunos
- e. Gerar o csv com o resultado (formato a definir)

f. Construir um dataset card

3. **(3,0) Classificação de Texto:** Usando o dataset de questões, classifique as questões por área de conhecimento usando como forma de representação dos textos:

- a. Técnica de Bag of Words (BoW) + TFIDF, configure e justifique parâmetros escolhidos, tal como o comprimento da BoW.
- b. Word Embeddings:
 - i. Teste um modelo estático como: `pt_core_news_lg` do Spacy
 - ii. Teste um modelo transformer como `bert-base-uncased` (algum modelo BERT)
- c. Análise e Compare os Resultados.

4. **(2,0) Similaridade de Palavras:**

- a. Usando o dataset de palavras que você construiu e o feito em aula, teste a similaridade com 3 modelos de linguagem:
 - i. um modelo estático como: `pt_core_news_lg` do Spacy
 - ii. um modelo transformer como `bert-base-uncased` (algum modelo BERT)
 - iii. um LLM de sua preferência
- b. Análise e Compare os Resultados.

Entregáveis:

- Corpus de Questões
- Corpus similaridade
- Classificador de questões
- Analisador de similaridade de palavras
- Apresentação descrevendo o processo de construção, análise e comparação de resultados
- **Data de entrega: conforme cronograma**

Observações:

- O uso de ferramentas de IA deve ser mencionado explicitamente no trabalho.
- No dia da apresentação todos os integrantes do grupo devem estar presentes.
- O domínio sobre o trabalho realizado será avaliado na apresentação.
- A qualidade do dataset e metodologia de construção serão considerados na avaliação.

- A nota será determinada pela qualidade dos datasets, tarefas implementadas e principalmente pela análise dos resultados.